

Ecole d'Été sur
**L'INTELLIGENCE
ARTIFICIELLE**

Classificateur de fonction de protéines

IA et Biologie : de la compréhension de l'ADN
à la distillation de modèles


ATELIER bioIA • SAMEDI 8 AOÛT 2026

Le problème

De l'ADN à la protéine : le dogme central

Trois étapes, toujours les mêmes


- **L'ADN** stocke l'information, écrite avec quatre lettres : A, T, G, C



De l'ADN à la protéine : le dogme central

Trois étapes, toujours les mêmes


- **L'ADN** stocke l'information, écrite avec quatre lettres : A, T, G, C
- **La transcription** en recopie un morceau en ARN



De l'ADN à la protéine : le dogme central

Trois étapes, toujours les mêmes

- **L'ADN** stocke l'information, écrite avec quatre lettres : A, T, G, C
- **La transcription** en recopie un morceau en ARN
- **La traduction** lit cet ARN *trois lettres à la fois*, chaque triplet (codon) désigne un acide aminé, et la chaîne d'acides aminés forme une **protéine**




De l'ADN à la protéine : le dogme central

Trois étapes, toujours les mêmes

- **L'ADN** stocke l'information, écrite avec quatre lettres : A, T, G, C
- **La transcription** en recopie un morceau en ARN
- **La traduction** lit cet ARN *trois lettres à la fois*, chaque triplet (codon) désigne un acide aminé, et la chaîne d'acides aminés forme une **protéine**

Ce qu'il faut retenir

Seules certaines portions de l'ADN suivent ce chemin jusqu'à la protéine : ces portions particulières, ce sont les **gènes**.




Où sont les gènes ?

- Humain Plante Bactérie
nous travaillons avec des **bactéries** : des génomes petits et bien annotés
- Leur génome, c'est **des millions de lettres** à la suite : [3pt] ...ATGCTAGCTAGGCCGGCATG ...
- **Rien ne les sépare visuellement.** Pas de titres, pas d'espaces.

La question de la semaine

Notre tâche : **prédire où se trouvent les gènes**. On vous donne 200 lettres d'ADN — est-ce un morceau de gène, oui ou non ?



Ce n'est pas un exercice d'école

Chaque fois qu'un nouvel organisme est séquencé — une bactérie résistante aux antibiotiques, un virus, un microbe du sol — **quelqu'un doit trouver ses gènes**. C'est la première étape de toute la biologie moderne.

Et personne ne le fait à la main.

Un problème de « trouver l'aiguille »

Des millions de fenêtres possibles, deux réponses possibles. C'est exactement le type de tâche où l'IA est bonne... si on lui donne la bonne représentation des données.

4

LETTRES

~4 M


PAR GÉNOME

2

RÉPONSES

L'idée forte

L'opportunité : la biologie a ses propres modèles de langage



Langage naturel

Prédire le mot suivant

GPT : apprend la grammaire, la syntaxe et le sens

Séquences biologiques

Prédire le nucléotide suivant

DNABERT, Evo2... : apprennent la structure et la fonction biologiques


Evo2 : une représentation riche... mais un modèle énorme

L'idée : on demande à **Evo2** une **représentation riche** des ADN & on branche ensuite un petit classifieur dessus

Le problème : 7 milliards de paramètres.
Impossible à faire tourner sur un laptop ou un séquenceur de terrain.



La solution : la distillation

Le gros modèle « professeur » entraîne un modèle « élève » minuscule, en lui transmettant non pas la bonne réponse, mais **son degré d'hésitation**.





Ce que nous construirons


Cinq jours, un pipeline complet



Cinq jours, un pipeline complet



Cinq jours, un pipeline complet



1. Fenêtres d'ADN (k-mers)

ATGCTAGCTAGCTACG

ATGC
TGCT
GCTA
CTAG
TAGC
AGCT
GCTA
CTAC
TACG
...

2. Professeur (note avec hésitation)

Modèle professeur (Evo2 + petit classifieur)

Représentations Evo2
(pour chaque fenêtre)

	Prédiction (étiquette)	Hésitation (confiance)
Promoteur	0.92	
Enhancer	0.35	
Gène	0.10	
Enhancer	0.60	
Promoteur	0.82	
...	...	...

3. Élève (apprend des notes)

Modèle élève (sans Evo2)

Encodage simple
(ex: k-mers one-hot)

A	C	G	T
1	0	0	0
0	1	0	0
0	0	1	0
0	0	0	1
1	0	0	0
...	...	...	...

	Prédiction (étiquette)	Hésitation cible (enseignée)
Promoteur	0.92	
Enhancer	0.35	
Gène	0.10	
Enhancer	0.60	
Promoteur	0.82	
...	...	...

4. Évaluation

Performance de
l'élève vs baselines
(Jour 1)



Quelle part de
performance
récupérée ?



Professeur = modèle fort (Evo2)
qui fournit des notes + confiance




Distillation des connaissances




Élève = modèle léger
apprend sans voir Evo2

Cinq jours, un pipeline complet




- Tous les modèles sur un seul graphique : précision, taille, latence
- **Que garderiez-vous** pour un appareil de terrain ?

Cinq jours, un pipeline complet



- Sans aucune étiquette, que le modèle a-t-il découvert tout seul ?
- Une piste **optionnelle**, pour les groupes en avance



COMMENT ON TRAVAILLE

Vous complétez les trous, jour après jour.

Chaque matin, un notebook **incomplet** vous attend : le squelette est là, les morceaux qui comptent sont à vous.

Vous codez, nous passons si besoin, et le soir votre pipeline a avancé d'un cran.

En cinq jours, vous serez passés d'un génome brut à un modèle compressé que vous aurez construit, mesuré et compris.