


# Visualisation du Script `src/build_dataset.py`


Pipeline de transformation des génomes bruts en jeu de données d'apprentissage pour classification binaire

## 1. Lecture & Extraction des régions CDS (fichier GFF)

Le script identifie les positions `start`, `end` et le brin (+ ou -) pour chaque région codante.



## 2 & 3. Fenêtrage Glissant (Taille = 200 bp) & Génération des Étiquettes



## 4. Équilibrage des classes par génome, Mélange (Shuffle) & Export CSV

- **Équilibrage** : Nombre d'échantillons Label 0 = Label 1 par génome.
- **Mélange** : Les fenêtres sont mélangées de manière aléatoire.
- **Sauvegarde** : Génération des fichiers `.csv` pour chaque split (train, val, test).

| Séquence (200 bp) | Label |
|-------------------|-------|
| ATGCG . . . TGA   | 1     |
| CCGAT . . . AAC   | 0     |
| TTGCA . . . CGT   | 1     |